

Discover More
Information



Create Further
Knowledge



Deliver Better
Solutions



AI신용평가모형 개발과정

01

AI신용평가모형

AI신용평가모형 정의
활용 사례
개발 방법론

02

머신러닝

머신러닝의 정의
머신러닝의 종류
모형의 평가와 선택

03

AI알고리즘

회귀분석
Deep Learning
Decision Tree

04

설명가능한 인공지능(XAI)

XAI정의
LIME/SHAP
사유코드
XAI 분석 사례

INDEX

Knowledge, Information, Solution

01 AI신용평가모형이란?

- (1) AI신용평가모형의 정의
- (2) AI신용평가모형 활용 사례
- (3) AI신용평가모형 개발 방법론

AI(Artificial Intelligence)?

 **You**
ai가 뭐야?

 **ChatGPT**

AI는 "Artificial Intelligence"의 약어로, 인공지능을 의미합니다. 이는 컴퓨터 시스템이 인간과 유사한 지능적 작업을 수행할 수 있는 능력을 가지고 있음을 나타냅니다. 인공지능은 머신러닝, 딥러닝, 자연어 처리, 컴퓨터 비전 등의 다양한 기술과 분야를 포함하며, 이러한 기술들을 사용하여 문제를 해결하고 데이터를 분석하며 패턴을 발견하고 예측하는 등의 작업을 수행할 수 있습니다. 인공지능은 거의 모든 산업 및 부문에서 적용되고 있으며, 우리의 삶에 많은 영향을 미치고 있습니다.

AI(Artificial Intelligence)?

01 이야기 생성

- J You**
토끼와 거북이 이야기를 만들어줘
- J You**
토끼가 이기는 이야기로 만들어줘
- J You**
역전에 역전을 거듭하는 이야기로 만들면 더 재미있을 것 같아
- ChatGPT**
그럼 역전에 역전을 거듭하는 재미있는 이야기를 만들어 보겠습니다.

한 번에 한 마일씩 경주하는 토끼와 거북이의 이야기를 역전에 역전을 거듭하는 이야기로 재구성해 보겠습니다.

어느 날, 숲 속에 사는 토끼와 거북이가 서로 경주를하기로 결정했습니다. 경주가 시작되자 토끼는 빠르게 뛰어나가며 거북이를 뒤로 남겼습니다. 토끼는 자신의 빠른 속도와 민첩한 다리로 경주에서 이길 것을 확신했습니다.

하지만 경주가 시작된 지 얼마 되지 않아 토끼는 물에 빠져버렸습니다. 토끼가 빠져버린 것을 보고 거북이는 이를 이용하여 토끼를 따라잡을 수 있는 기회를 잡았습니다. 거북이는 천천히 하나씩 발걸음을 내딛으며 꾸준히 앞으로 나아갔습니다.

그러나 토끼는 물에서 빠져나와 다시 달리기를 시작했습니다. 토끼는 역전의 기회를 열등감 없이 받아들여 빠른 속도로 앞으로 나아갔습니다. 그리고 토끼는 경주의 선두에 서게 되었습니다.

하지만 그 순간, 토끼는 지나치게 자만심에 빠져 멈추어 쉬었습니다. 이를 이용한 거북이는 다시 천천히 발걸음을 내딛어 토끼를 따라잡았습니다.

그리하여 경주는 역전에 역전을 거듭하며 계속되었습니다. 토끼와 거북이는 번갈아가며 선두를 바꾸며 경주를 이어나갔습니다.

마침내, 경주의 목표지점에 다가온 순간, 토끼와 거북이는 함께 도착했습니다. 그들은 함께 경주를 끝내며 서로를 칭찬하고 함께 즐거운 시간을 보냈습니다.

그리하여 숲 속의 흥미진진한 이야기로 유명한 토끼와 거북이의 이야기는 역전에 역전을 거듭하여 결말을 이루었습니다.

02 이미지 생성



03 자율 주행



AI신용평가모형이란?

AI신용평가모형은

머신러닝 방법론을 신용평가모형에 적용하여 부도 예측 성능을 크게 향상 시킨 신용평가모형

사회적 효용을 증가시킬 수 있지만 소비자의 권리 보호가 최우선으로 **제한적으로 적용 중**

XAI 방법론을 활용하여 이를 보완할 수 있으며 소비자의 권리를 보호와 사회적 효용의 증가를 동시에 상승 시킬 수 있음

AI신용평가모형이 뭔가요?

신용평가모형은 고객의 대출 심사를 위한 부도 예측 모형을 의미합니다. 위험 평가 수준에 따라 승인 여부, 대출한도, 금리가 결정됩니다.
AI신용평가모형은 부도 예측모형에 위하여 Deep Learning으로 대표되는 Machine Learning 기술을 적용한 모형을 의미합니다.
최신 기술을 이용하여 부도 예측 성능이 상승하면 고객과 금융 회사 모두에게 이익이 되며 사회적 효용을 증가시킬 수 있습니다.

모든 평가를 AI모형으로 하나요?

AI신용평가모형의 활용은 아직 제한적입니다. 대출 심사를 위한 신용평가를 할 때에는 불합리한 이유로 고객을 차별해서는 안되고, 심사 결과를 고객 한 명 한명에게 납득시킬 수 있어야 합니다.
AI모형의 Black-Box라고 부를 정도로 복잡하여 개개인이 어떤 이유로 평가를 받게 되었는지 확인이 어렵습니다. 이런 이유로 대출 심사의 모든 과정에 적용되기 보다는 거절 대상자를 추가 승인하는 전략을 위한 목적으로 제한적으로 사용되고 있습니다.

극복 방안은 없나요?

AI 알고리즘은 결과의 성능을 향상시키는 방향으로 발전되어 왔습니다. 최근에는 결과를 설명하기 위한 방법론에 많은 연구가 진행되고 있습니다.
XAI(eXplainable AI, 설명가능한 인공지능)라고 하는 연구 분야로 대표적으로 LIME, SHAP 등의 기법이 있습니다. 이를 활용하면 AI신용평가모형을 실무에 적용시킬 수 있습니다.

금융소외계층 은행 대출 활성화(2019.04)

금융감독원, 190403_조간_19년 하반기부터는 사회초년생 등 금융소외계층에 대한 은행대출이 한결 수월해 집니다

- 금융감독원은 최근 정부가 추진중인 비금융정보 활성화 정책*이 은행권에도 안정적으로 정착되도록 이행상황 등 점검을 강화할 계획
- * 금융위는 「신용정보법」 개정('18.11월 발의)을 통해 비금융정보 전문 CB 도입, 금융권 정보공유 확대 등 신용정보산업 선진화 방안을 마련중
- 향후 금융소비자가 신뢰할 수 있는 은행 신용평가 방안이 마련되도록 평가항목의 다양화, 모형의 고도화 등을 추진해 나갈 예정

< 중·장기 추진계획 >

주요 내용		일정
❶ 평가항목의 다양화	비금융정보 전문 신용조사회사(CB) 도입 등 이용가능한 정보의 확대에 맞춰 평가항목의 다양화를 유도	(중기)
❷ 평가모형의 고도화	머신러닝 등 빅데이터 기반의 최신 방법론을 활용한 신용평가모형의 구축 및 활용*을 독려	(중·장기)

* 다만, 머신러닝 등 최신방법론은 우량 고객을 선별하는 능력은 우수하나 현행 방법론 대비 복잡하고 결과에 대한 해석 및 설명이 용이하지 않아 장기적 관점의 연구가 필요함

금융분야 AI 신용평가모형 가이드라인(2023.04)

금융위원회, 230417 (보도자료) AI 기반 신용평가모형 및 금융분야 AI 보안 가이드라인 마련

금융위원회는 지난 2022년 8월, 금융권의 인공지능(Artificial Intelligence, AI) 활용을 지원하기 위해 「금융분야 인공지능 활용 활성화 및 신뢰확보 방안」을 발표하였다. 해당 방안의 후속조치로 신뢰받는 인공지능 활용 환경을 구축하기 위해 「AI 기반 신용평가모형 검증체계」와 「금융분야 AI 보안 가이드라인」을 마련했다.


AI 기반 신용평가모형 검증체계는 AI 특성을 고려하여 신용정보회사가 데이터를 적절히 관리하면서, 신용평가모형에 사용되는 알고리즘과 변수를 합리적으로 선정하였는지 점검하고, 신용정보회사가 개발한 신용평가모형이 통계적으로 유의한지 확인한다. 또한, 신용정보회사가 금융소비자에게 신용평가모형과 신용평가 결과에 대해 충분히 설명할 수 있는지 검증한다.

개인신용평가체계 검증위원회는 「AI 기반 신용평가모형 검증체계」를 활용하여 연내 AI 신용평가모형을 활용하고 있는 개인사업자신용평가회사에 대한 검증을 수행할 예정이다. 향후 개인신용평가회사 등의 AI 신용평가모형에 대해서도 검증을 실시할 계획이다.

Keyword

AI신용평가모형, 성능, 설명, 권리 보호, 피해 방지

AI신용평가모형 적용 사례




Low-Side Override 적용

- 구성비 23.5%, 불량률 3.0%

등급1	등급2									
	1	2	3	4	5	6	7	8	9	10
1										
2										
3										
4										
5										
6										
7										
8										
9										
10										

AI모형	구성비	불량률	판정결과
1	2.10%	1.10%	자동승인
2	4.00%	2.00%	
3	8.00%	2.70%	
4	9.40%	4.00%	
5	7.80%	6.00%	정밀심사
6	6.50%	7.10%	
7	4.10%	8.90%	
8	5.20%	11.20%	
9	4.20%	15.90%	
10	2.00%	24.30%	



1) 금융부족군: 학생, 주부, 사회초년생 등 금융활동 초기에 신용을 정확하게 평가 받기 어려움


AI신용평가모형 설명방법1: 사유코드

사유코드는 XAI 방법론 중 전역 대리자 모형(Global Surrogate Model) 방법의 일종입니다.
소비자를 위한 설명 방법론으로 모형 구성단계에서 사회적 의미와 설명을 고려하기 때문에 직관적으로 좋은 설명을 제공할 수 있습니다.

	Recode	Range	Beta	배점
연체건수	0	2건 이상	0	0
	1	1건	1.2	11
	2	0건	2.6	55
대출금액	0	A구간	0	0
	1	B구간	1.5	23
	2	C구간	3.1	65
카드실적	0	신용카드 실적 없음	0	0
	1	월 n만원 이하	3.1	36
	2	...	...	72

※ Black-Box 모형: 50개 알고리즘 앙상블 + 약 80개 항목

WHY? 감점사유 산출 비율



- 감점 사유가 산출되지 않은 대상
- 감점 사유가 1개 이상 산출된 대상

AI신용평가모형 설명방법2: SHAP


SHAP을 이용한 AI모형의 설명 기법은 최근 많은 관심을 받고 있는 방법론입니다.

AI모형의 결과값에 미치는 영향을 개별 항목 수준에서 쉽게 확인할 수 있습니다.

연산 속도에서 단점을 보이는 방법론이지만 Tree기반의 알고리즘에서 빠르고 정확하게 원인을 파악할 수 있습니다.


Beeswarm

- ✓ 개별 항목의 값이 출력값에 어떤 영향을 미쳤는지 전체적으로 확인
- ✓ 가로축의 값이 클수록 모형 결과에 가점
- ✓ 개별 항목의 값이 클수록 빨간색, 작을수록 파란색에 가깝게 표현



Waterfall

- ✓ 개별 데이터에 대한 AI모형의 결과값을 항목별로 분해
- ✓ 가점과 감점을 각각 빨간색, 파란색으로 표현하며 높은 정확도를 보임
- ✓ 평점 상승을 위한 대안을 찾기 어려움(낮은 대조성)



신용평가모형 개발 방법론


신용평가모형 개발 방법론은 전통적인 평점표 방법론과 AI 개발 방법론으로 크게 구분할 수 있습니다.
리스크를 수치화하여 표현한다는 목적은 동일하지만 결과물의 형태와 이를 도출하는 과정에서 차이를 보입니다.

평점표 방법론 Logistic 을 활용한 평점표 형태 모형

관심사 과정과 의미 중심

특징 15개 내외의 항목으로 설명하기 용이한 형태로 표현

Process




AI 방법론 여러가지 알고리즘의 앙상블 모형

관심사 결과의 퍼포먼스 중심

특징 50~100개 내외의 항목을 활용
설명을 위한 별도의 대리자 모형 구성

Process



신용평가모형 개발 방법론

신용평가모형 개발 방법론은 전통적인 평점표 방법론과 AI 개발 방법론으로 크게 구분할 수 있습니다.
리스크를 수치화하여 표현한다는 목적은 동일하지만 결과물의 형태와 이를 도출하는 과정에서 차이를 보입니다.

영역	기존방법론	AI방법론	시사점
활용 데이터	- 제한된 정보 영역 - 개발자 수기 가공 10~15개 항목 활용	- 다양한 정보 항목 - 개발자 수기 가공 - 알고리즘을 활용한 자동 가공 - 항목 개수에 제한 없음 (100개 내외)	- SNS데이터, 스크래핑 데이터, 심리평가 데이터 등 새로운 Big Data 활용 - 새로운 영역의 데이터를 활용하여 유의미한 항목을 자동으로 생성하여 반영 - 다양한 형태의 정보를 모형에 결합하여 결과 산출
알고리즘	Logistic Regression	- Deep Neural Network - Gradient Boosting Machine (GBM, XGBoost, LightGBM) - Random Forest - Logistic Regression	한정된 회귀분석 방법론만이 아닌, 다양한 방법론을 모두 고려하므로 데이터의 종류에 따라 최적의 방법론으로 모형 생성이 가능함

주요 알고리즘

신용평가모형을 개발하는데 자주 사용되는 알고리즘입니다.

Binary Classification에 해당하는 신용평가모형에서는 Tree계열의 알고리즘이 많이 활용되고 있습니다.

알고리즘	일반화능력	학습시간	선형성	변별력	사용빈도	참고사항
Logistic Regression	○	●	●	○	○	- 상대적으로 낮은 Variance를 가지는 알고리즘으로 학습시간이 빠르고 분포가 잘 퍼진다는 장점이 있음 - 선형모형으로서 스코어 산출 원인을 확인 가능
Random Forest	○	○	○	●	●	- 변별력이 좋은 알고리즘이지만 과적합 확률이 높음 - 유사한 Tree Base의 GBM 알고리즘보다 변별력이 다소 낮은 경향이 있음
Gradient Boosting Machine	●	○	○	●	●	- 국내외적으로 신용평가에서 가장 많이 사용 - 변별력은 좋으나 과적합의 확률이 다소 높음 - XGBoost, LightGBM 으로 발전
Deep Neural Network	○	○	○	●	●	매개 변수가 많아 유연성 및 정확도가 뛰어난 알고리즘이지만 최적의 조합을 찾는 데 다수의 시행착오가 필요

주) (●) 뛰어난 정확도, 빠른 학습시간, 선형성 사용, (○) 양호한 정확도, 보통의 학습시간, 선형성 미사용

주요 알고리즘

Logistic Regression은 전통적인 신용평가모형 개발방법론에서 사용되어온 알고리즘입니다.
알고리즘을 적용하는 방법에 따라 평점표 형태로 구성할 수 있습니다.


1. 특징

- 설명변수(X)와 종속변수(Y)간의 관계를 선형으로 가정하고 이를 잘 표현할 수 있는 회귀계수 추정
 - ✓ 선형가정을 가정함으로써 개별 항목에 대한 설명 가능, Noise에 강함
 - ✓ 0과 1로 구분된 Binary Classification에 활용됨

2. Logic

$$\ln\left(\frac{P}{1-P}\right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k$$

- 목적식(Likelihood Function)을 최대화
 - ✓ 선택된 변수를 사용하여 목적식이 최대화되는 계수 추정
 - ✓ 변수선택 방법에 따라 변수를 추가, 또는 제거
 - ✓ 목적식이 최대화되는 변수의 조합과 계수를 추정



3. 고려사항

- 변수선택 방법
 - ✓ Stepwise, Forward, Backward
- Regularization
 - ✓ 많은 변수를 포함하는 경우 모형의 복잡도가 증가하는 경우 모형 계수에 제약을 적용하여 과적합 제어
 - ✓ 라쏘패널티(L1패널티): 변수의 개수를 제약하는 효과
 - ✓ 리지패널티(L2패널티): 개별 변수의 민감도를 제약하는 효과

주요 알고리즘


Random Forest는 앙상블 학습 방법의 일종으로, 다수의 Decision Tree로부터 평균 예측치를 구하여 모형적합을 수행합니다.

1. 특징

- 임의복원추출에 의해 서로 조금씩 다른 특성을 갖는 트리 구성 후 예측 결과 조합
 - ✓ 배깅(Bagging) : (Bias 유지 + Variance 감소) → 일반화 능력 향상
 - ✓ 임의 노드 최적화(Randomized Node Optimization) : (Tree 간 상관성 감소) → Noise에 강함

2. Logic

- 배깅(Bagging) = Bootstrap + Aggregating
 - ✓ Bootstrap : 임의복원추출을 통해 T개의 Training Set 생성
 - ✓ 각 Training Set에서 Decision Tree 훈련
 - ✓ Aggregation : 각 Tree의 결과 취합
 - 범주형 Target은 최빈값(mode),
 - 연속형 Target은 평균(average)
- 임의 노드 최적화(Randomized Node Optimization)
 - ✓ 훈련 목적 함수(Information Gain)를 최대로 만드는 노드 분할 함수의 매개 변수 θ 의 최적값을 산출



3. 고려사항

- 포레스트의 크기(트리의 개수)
 - ✓ 크면 일반화 능력 증가(훈련 시간 증가), 작으면 일반화 능력 감소(훈련 시간 감소)
- 최대 허용 깊이
 - ✓ 깊으면 과대적합(overfitting), 얕으면 과소적합(underfitting)
- 훈련 목적 함수, 임의성의 정도(the amount of randomness), 노드 분할 함수 등

주요 알고리즘


Gradient Boosting Machine(GBM)은 Decision Tree의 시퀀스 학습을 통해 예측 모델을 생성하며, 이전 Tree의 예측 오류를 수정해 나가며 모형적합을 수행합니다.

1. 특징

- 부스팅 알고리즘(Boosting Algorithm)에 의해 추출된 표본으로 트리 구성 후 예측 결과 조합
 - ✓ Bootstrap 표본 추출에서 전 단계 모형에서 오분류된 Data 추출 확률을 높게 설정하여 표본 추출
 - ✓ 각 모형의 정확도에 따라 다른 가중치를 부여한 후 평균 → **가중평균**

2. Logic

- Gradient Boosting Model
 - ✓ **Gradient Descent** :
각 Training Set에서 Loss Function이 최소화되도록 Classifier 적합
 - ✓ **Boosting** :
이전 모형에서 오분류된 Data 추출 확률을 높게 설정하여 표본 추출 후 Classifier 적합
 - ✓ **Ensemble** :
생성된 Classifier의 정확도에 따라 가중치를 달리 하여 결합(평균)



3. 고려사항

- 포레스트의 크기(트리의 개수)
 - ✓ 크면 일반화 능력 증가(훈련 시간 증가), 작으면 일반화 능력 감소(훈련 시간 감소)
- 최대 허용 깊이
 - ✓ 깊으면 과대적합(overfitting), 얕으면 과소적합(underfitting)
- 학습률(Gradient Descent : $\theta_j := \theta_j - \alpha * \nabla J(\theta_j)$) 등

주요 알고리즘


딥러닝(Deep Learning)은 여러 층으로 되어있는 복잡한 구조의 인공신경망 Deep Neural Network(DNN)을 의미합니다. 특정 분야(음성, 이미지 인식 등)에서는 (인간의 능력과 유사할 정도로) 우수한 성능을 나타내기도 합니다.

1. 특징

- 인공신경망(ANN)의 한계를 극복하기 위해 제안된 기계 학습 방법
 - ✓ Pre-training을 통해 적절한 Initial Weight를 구하여 기존 Neural Network의 Overfitting 문제 해결
 - ✓ Unsupervised pre-training 과정을 통한 Noise 감소 효과

2. Logic

- 딥 러닝(Deep Neural Network) 알고리즘
 - ✓ 1st Hidden Layer Pre-Training
 - ✓ 1st Output을 2nd Hidden Layer의 Input으로 Pre-Training
 - ✓ 모든 Hidden Layer에서 순차적인 Pre-Training 시행
 - ✓ Pre-Training으로 구해진 Weights를 초기값으로 ANN 알고리즘 시행



3. 고려사항

- 층(Layer)의 개수, 정보 진행 방향(Forward, Backward), 각 층(Layer)의 노드(Node) 수
- 활성 함수(Activation Function)
 - Tanh(Sigmoid 함수를 $[-1, 1]$ 로 범위 확장), Rectifier($f(x) = \max(0, x)$), Max-Out(Rectifier의 일반화 형태) 등
- 역전파 알고리즘 - 학습률(Gradient Descent : $\theta_j := \theta_j - \alpha * \nabla J(\theta_j)$), 반복(Epoch) 등
- 입력 Dropout Ratio, Hidden Dropout Ratio, Auto Encoder 사용여부

INDEX

Knowledge, Information, Solution


02 머신러닝이란?

- (1) 머신러닝 정의
- (2) 머신러닝 종류
- (3) 모형의 평가와 선택

머신러닝의 정의

데이터(Data)로 가치있는 결과(Results)를 만들어내는 방법론이 바로 머신러닝입니다.

1. 머신러닝 (Machine Learning)




“A computer program is said to learn from experience E with respect to some class of tasks T and performance measure P, if its performance at task in T, as measured by P, improves with E”


기계가 학습을 한다는 것은 특정한 과업(task)를 수행하기 위해 다양한 경험(데이터)으로부터 프로그램을 진화시키는 것을 학습이라 정의하며, 이러한 학습이 가능하기 위해서는 얼마나 과업을 잘 수행했는지를 평가할 수 있는 평가 지표(performance measure)가 있어야 함을 의미한다.

Mitchell, T. M. (1997). Machine learning. WCB.


2. 데이터마이닝 (Data Mining)



3. 빅데이터 (Big Data)



4. 인공지능 (Artificial Intelligence)



AI와 머신러닝

AI는 인간의 지능을 모방하려는 개념적 기술로 시작해, 예측 중심의 AI를 거쳐 생성형 AI로 발전해왔습니다.
신용평가모형은 여전히 예측 중심의 AI에 기반하지만, 생성형 AI와의 융합 가능성도 함께 주목받고 있습니다.

AI (Artificial Intelligence) ~1950s

인간 지적 능력을 컴퓨터로 구현하는 기술
인간의 학습, 추론, 문제 해결 능력을 모방

Machine Learning ~1960s

데이터를 기초로 기계가 스스로 규칙을 학습하는 기술
명시적인 프로그래밍 없이 기계 스스로 예측하거나 결정

Deep Learning ~2010s

인공 신경망을 활용하여 대규모 데이터에서 복잡한 패턴을 학습
자연어, 이미지, 소리 등 **비정형 데이터 분석에 강점**

생성형AI 2010s~

텍스트, 이미지, 오디오 등 새로운 **콘텐츠를 생성**하는 기술
대규모 데이터의 패턴을 학습하여 창의적인 결과물 생성

LLM 2017~

Attention is All You Need.

인간의 언어를 이해하고 생성하는 기술
맥락을 파악하고 논리적인 문장을 생성

Discriminative AI
Predictive AI
Traditional AI

Generative AI

머신러닝의 분류

머신러닝은 데이터의 속성에 따라, 과업의 종류에 따라, 예측수행횟수와 모형업데이트 빈도에 따라 다양한 방식으로 구분될 수 있습니다.

데이터 속성

데이터 타겟의 유무에 따른 분류

- 지도학습(Supervised Learning)
- 비지도학습(Unsupervised Learning)
- 준지도 학습(Semi-Supervised Learning)

과업의 종류

모형개발 목적에 따른 분류

- 분류 문제(Classification)
- 회귀 문제(Regression)
- 이상치 탐지 문제(Novelty Detection)
- 군집화 문제(Clustering)
- 연관규칙 분석(Association Rule)

예측횟수 업데이트 방식

“모델 업데이트 방식”에 따른 분류

- 정적 학습(Static Learning)
- 증가 학습(Incremental Learning)
- 강화 학습(Reinforcement Learning)

머신러닝의 분류: 데이터 속성

데이터의 속성(타겟의 유무)에 따라 머신러닝은 지도학습과 비/준지도 학습으로 구분될 수 있습니다.

지도학습 (Supervised Learning)

A given dataset **X & Y**

	Var. 1	Var. 2	...	Var. d	
Ins. 1	..	..	...	..	$y = f(x)$
Ins. 2	..	..	...	..	
...	...	...	...	...	
Ins. N	..	..	..	..	

비지도학습 (Unsupervised Learning)

A given dataset **X**

	Var. 1	Var. 2	...	Var. d
Ins. 1	..	..	...	..
Ins. 2	..	..	...	..
...	...	...	...	...
Ins. N	..	..	..	..

준지도학습 (Semi-supervised Learning)


A given dataset **X & Y**

	Var. 1	Var. 2	...	Var. d	
Ins. 1	..	..	...	..	$y = f(x)$
Ins. 2	..	..	...	..	
...	...	...	...	...	
Ins. N	..	..	..	..	
...	...	...	...	...	
...	...	...	...	...	
...	...	...	...	...	
...	...	...	...	...	
Ins. M	..	..	..	..	


머신러닝의 분류: 과업의 종류

과업의 종류에 따라 머신러닝을 분류 문제, 회귀 문제, 이상치 탐지 문제, 군집화 문제, 연관규칙분석 등으로 구분할 수 있습니다.


분류 (Classification)




회귀 (Regression)




이상치 탐지 (Novelty Detection) 밀도 기반 이상치 탐지



거리 기반 이상치 탐지



군집화 (Clustering)



머신러닝의 분류: 업데이트 방식

“모델 업데이트 방식”에 따른 머신러닝 기법을 정적 학습과 증가 학습 그리고 강화 학습으로 구분할 수 있습니다.

구분	정적 학습 (Static Learning)	증가 학습 (Incremental Learning)	강화 학습 (Reinforcement Learning)
정의	전체 데이터셋을 한 번에 사용하여 학습하는 방법	새로운 데이터를 점진적으로 학습하는 방법	에이전트가 환경과 상호 작용하며 보상을 통해 학습하는 방법
데이터 처리	정적 데이터셋을 사용	데이터를 지속적으로 수집	환경과의 상호작용을 통해 데이터 생성
모델 업데이트 방식	전체 재학습 (Fully updated)	일부 재학습 (Partially updated)	선택적 학습 (Adaptively updated)
목적	주어진 데이터에 최적의 모델 생성	새로운 정보에 적응 및 성능 개선	장기적인 보상을 최대화하는 정책 학습
사용 예	일반적인 지도 학습, 비지도 학습	온라인 학습, 시계열 데이터 분석	게임AI, 자율 주행

머신러닝의 분류: 강화학습

강화학습은 보상을 타겟으로 하는 기법으로, AI의 개념처럼 Action을 학습하는 것이 가능합니다.


강화학습 개념 및 사례

- 행동심리학에서 영감을 받은 머신러닝의 한 영역
- 어떤 환경 안에서 정의된 에이전트가 현재의 상태를 인식하여, 선택 가능한 행동들 중 보상을 최대화하는 행동 혹은 행동 순서를 선택하는 방법
- DeepMind의 AlphaGo, 자율주행차 등 강화학습 적용 사례 존재



강화학습 구성

- Environment Modeling: 특정 상태에서 어떤 액션을 수행하였을 때의 결과를 통해 환경에 대해 모델링을 함
- Agent Modeling: Agent가 환경과 상호작용을 하면서, 현재 상태에서 기대되는 보상이 최대가 되도록 최적의 정책(Optimal Policy)을 찾는 것



머신러닝의 분류: 강화학습 - 사례

대출 심사 결과에 따른 고객의 행동 패턴을 반복적으로 평가함으로써 최상의 심사 정책을 도출할 수 있습니다.



모형 평가 지표

만들어진 모형을 평가하는 다양한 Performance Measure가 존재합니다.
최종 모형을 선택하기 위하여 적절한 지표를 선택해서 활용하며, 학습 지표에 반영하기도 합니다.

	평가 지표(Model Evaluation Metrics)	학습 지표(Training Metrics)
정의	모델의 성능을 평가하기 위해 사용되는 지표	모델 훈련 중 손실이나 성능을 측정하는 지표
목적	새로운 데이터에 대한 일반화 성능을 측정	모델의 학습 과정에서의 성능을 모니터링
예시	정확도, 정밀도, 재현율, F1 점수, AUC, MSE, MAE	손실 함수 (MSE, MAE, 크로스 엔트로피 등)
활용 데이터	테스트 데이터셋을 사용	훈련 데이터셋을 사용
주요 관심사	모델이 실제 문제를 얼마나 잘 해결하는지	모델이 과적합하지 않고 적절히 학습하고 있는지

모형 평가 지표

만들어진 모형을 평가하는 다양한 Performance Measure가 존재합니다.
Regression의 Performance Measure로서 MAE, MSE, RMSE 등이 있습니다.

$$\text{Mean Absolute Error (MAE)} = \frac{1}{n} \sum_{i=1}^n |y - \hat{y}|$$

$$\text{Mean Absolute Percent Error (MAPE)} = 100\% \times \frac{1}{n} \sum_{i=1}^n \frac{|y - \hat{y}|}{|y|}$$

$$\text{Mean Squared Error (MSE)} = \frac{1}{n} \sum_{i=1}^n (y - \hat{y})^2$$

$$\text{Root Mean Squared Error (RMSE)} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y - \hat{y})^2}$$

만들어진 모형을 평가하는 다양한 Performance Measure가 존재합니다. Regression의 Performance Measure로서 MAE, MSE, RMSE 등이 있습니다.

Mean Absd

Mean Absc

Mean Squ

Root Mean

모형 평가 지표 – KAGGLE Bicycle 경진대회

데이터 과학과 머신 러닝 경진대회를 개최하고, 데이터셋과 커뮤니티를 통해 학습 및 협업할 수 있는 세계적인 플랫폼 Kaggle에서 Bicycle 경진대회는 교육을 위한 예제로서도 많이 활용되고 있습니다.



Kaggle Bicycle 경진대회

목적

- 자전거 대여시스템의 시간대별 자전거 수요를 예측
- 대중교통 시스템의 효율성 향상 및 운영 최적화

데이터

- 시간, 요일, 날씨, 온도, 공휴일 여부 등 다양한 변수 포함.
- 대여 기록 데이터를 바탕으로 자전거 수요 패턴을 분석.

모델

- 주로 회귀 모델 사용: 선형 회귀, 랜덤 포레스트, XGBoost, 딥러닝 모델 등.
- 시계열 분석과 머신러닝 기법 적용.

평가지표

RMSLE (Root Mean Squared Logarithmic Error)



예측값과 실제값 간 로그 차이를 기준으로 오차를 계산

- 과소 예측에 더 큰 페널티를 주어 정확도를 높임.
- 큰 오차에 덜 민감하여 대여 수요처럼 변동이 큰 데이터를 다루는 데 적합.

$$RMSLE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\log(pred_i + 1) - \log(actual_i + 1))^2}$$

모형 평가 지표

Bycycle 경진대회에서는 RMSLE 라는 평가지표를 활용함으로써, 자전거 수요가 많은 대여소에서는 패널티를 적게 부여하고, 과대 추정보다 과소 추정에 더 많은 페널티를 부여하였습니다.



모형 평가 지표

만들어진 모형을 평가하는 다양한 Performance Measure가 존재합니다.
신용평가와 같은 Classification의 경우 Confusion Matrix를 사용할 수 있습니다.

	Predicted Class	
Actual Class	Yes	No
Yes	TP(True Positive)	FN(False Negative)
No	FP(False Positive)	TN(True Negative)

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

	Predicted Class	
Actual Class	Yes	No
Yes	C(Yes Yes)	C(No Yes)
No	C(Yes No)	C(No No)

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

$$F - Measure = \frac{2TP}{2TP + FP + FN}$$

모형 평가 지표

만들어진 모형을 평가하는 다양한 Performance Measure가 존재합니다.
신용평가와 같은 Classification의 경우 Confusion Matrix를 사용할 수 있습니다.

	Predicted Class	
Actual	불량	우량
불량(10)	7	3
우량(90)	13	77

↔

	Predicted Class	
Actual	불량	우량
불량(10)	7+2	3-2
우량(90)	13+18	77-18

Precision=7/20=14/40
Recall = 7/10


Precision=9/40
Recall = 9/10

신용평가모형 주요 평가 지표

신용평가에서 가장 많이 사용하는 Classification Measure로서 K-S, AUC, CAP가 있습니다.

CAP, Lorenz AR(Accuracy Ratio)

로직	AR (Accuracy Ratio) : CAP curve(Gini Curve, Lorenz Curve, Power Curve) 의 요약 통계량 AR과 AUROC의 관계 : $AR = 2 \times AUROC - 1$ AR값은 일반적으로 50%~80% 사이의 값임
가이드	• 우량차주와 불량차주의 구성비에 의해 CAP Curve 도출 • 모든 차주를 신용평점이 낮은 순에서 높은 순으로 나열한 뒤, 동일한 구성비로 차주를 나누었을 때 • 가로축은 검증자료의 누적 확률, 즉 검증자료의 누적 구성비이고 세로축은 누적 불량율로 정의됨. • 불량차주가 전체적으로 적은 포트폴리오의 경우와 불량차주가 상대적으로 많은 포트폴리오의 경우 CAP 모양이 달라질 수 있기 때문에 CAP 곡선의 모양을 단순히 비교하는 것은 결과를 왜곡시킬 수 있음.



- 변별력 검증은 신용평가모형의 우량건과 불량건을 얼마나 잘 구별해내는가 검증하는 것으로 CAP 곡선 및 ROC 곡선의 경우 직관적으로 이해하기가 쉬움.
- 완전한 모형(Perfect model)은 부도차주에게 최고로 낮은 스코어가 주어짐.
- 무작위 모형(Random model)은 전체누적구성비에 대해 불량누적구성비가 무차별함.
- 일반적인 신용평가모형은 완전한 모형과 무작위모형 사이에 위치함.

신용평가모형 주요 평가 지표

신용평가에서 가장 많이 사용하는 Classification Measure로서 K-S, AUC, CAP가 있습니다.



K-S(Kolmogorov-Smirnov Statistics)

로직

$\text{MAX}[|\text{누적우량\%} - \text{누적불량\%}|]$

가이드

- 신용평가모형이 우량차주와 불량차주를 잘 구분하는 변별력이 있는가를 판단하는데 사용
- KS Statistic은 평점대별 누적 우량구성비와 누적 불량구성비와의 Maximum Difference.
- 0~1사이의 값을 가지며, ASS : 0.30, BSS : 0.40 이상이 적합함.
- K-S 검정은 평가모형이 정상차주와 부도차주를 잘 구분하는 변별력이 있는가를 판단하는 데 사용되는 통계적 방법임.




[K-S 통계량이 모형성능지표인 경우]

- 검증자료의 불량률이 개발시점의 불량률과 유사
- 검증자료와 개발자료의 우량차주 분포와 불량차주분포가 유사
- 검증자료에 사용된 불량정의와 개발시점에서 사용된 불량정의가 동일할 때

모형의 선택

복잡한 모형을 만들 수록 모형의 편기(Bias)는 감소하지만, 분산(Variance)은 증가하게 됩니다. 다양한 방법론을 잘 선택하여 혹은 결합하여 에러가 낮은 모형을 만들어내야 합니다.




모형의 선택

Overfitting은 현재 Data와 정확히 일치하지만 새로운 Data가 들어왔을 때 일반화가 잘 되지 않는 경우를 말하며 모형의 복잡도가 높을 때 발생합니다. Training Set, Validation Set, Test Set을 충분히 검토하여 일반화된 모형을 선택해야 합니다.


Overfitting(과적합)

- **[Overfitting]** If we have too many features, the learned hypothesis may fit the training set very well, but **fail to generalize to new examples**


Example: Linear regression (housing prices)



High bias
(Under fit)






"Just right"



High variance
(Over fit)

Example: Logistic regression



Addressing Overfitting

- **Reduce number of features**
 - ✓ Manually select which features to keep.
 - ✓ Model selection algorithm(later in course)
- **Regularization**
 - ✓ Keep all the features, but **reduce magnitude/values of parameters θ**
 - ✓ Works well when we have a lot of features, each of which contributes a bit to prediction y .

$$\min_{\theta} J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2 \right]$$

INDEX

Knowledge, Information, Solution

03 AI 알고리즘

(1) 회귀분석

(2) Deep Learning

(3) Decision Tree


회귀분석의 종류

회귀분석의 경우 독립변수(X)의 영향이 종속변수(Y)에 직접적으로 가해지므로 그 의미를 해석하기 용이합니다.
추정된 계수(β)를 이용하여 모형을 직접 설명합니다.

Linear Regression

종속변수와 독립변수의 관계를
선형을 가정하고 회귀식을 정의
추정된 회귀 계수를 이용하여
각 독립변수의 영향도(부호, 크기)를 설명


$$E(Y|X) = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$$



Logistic Regression

종속변수가 0과 1로 구분되는 Binary Classification
에 적합한 회귀식
추정된 결과는 log ODDS 를 의미하며, 이를
이용하여 각 독립변수의 영향도를 설명

$$\log\left(\frac{P(Y=1|X)}{1-P(Y=1|X)}\right) = X \beta$$



Generalized Linear Regression

종속변수와 독립변수의 관계를 연결 함수를
이용하여 선형 회귀식을 표현
직접적인 선형관계를 가지지 않은 경우에도
효과적인 회귀 계수를 추정할 수 있음

$$E(Y|X) = g^{-1}(X \beta)$$

where g is a link function

① Logistic Regression


$$g(p) = \text{logit } p = \ln\left(\frac{p}{1-p}\right)$$

② Generalized additive model

$$\eta = \beta_0 + f_1(x_1) + f_2(x_2) + \dots$$

변수선택 방법


회귀분석의 변수의 선택은 전진선택법(Forward), 후진선택법(Backward)과 이를 결합한 Stepwise로 이루어집니다. 각각의 선택의 방법론은 Greedy 하여 최적을 보장하지 않으므로 장단을 고려해야 합니다.



<https://www.spcforexcel.com/knowledge/root-cause-analysis/stepwise-regression>

정규화(Regularization)

많은 변수를 포함하는 경우 모델의 복잡도가 증가하는 경우 모형의 계수에 제약을 포함시켜 과적합을 제어할 수 있습니다. Lasso의 경우 변수 선택의 효과도 확보할 수 있습니다.



[Ridge/Lasso/Elastic Net Regression]

- Elastic Net GLM은 Ridge와 Lasso를 적절히 선택할 수 있습니다. 알파를 1로 설정하면 라쏘 패널티, 0으로 설정하면 리지 패널티를 의미합니다(범위: 0~1.0). 알파를 1에 가까운 값으로 설정하면 소수의 변수만을 사용하는 효과가 있으며, 0에 가까운 값으로 설정하면 데이터의 변화에 대한 민감도가 감소하여 안정적인 모형 구축이 가능합니다.

$$\operatorname{argmin}_{\beta} \sum_{i=1}^N \operatorname{loss}(\beta) + \lambda(\alpha \|\beta\|_1 + \frac{1}{2}(1 - \alpha) \|\beta\|_1^2)$$

INDEX

Knowledge, Information, Solution

03 AI 알고리즘


(1) 회귀분석

(2) Deep Learning

(3) Decision Tree



Artificial Neural Network(ANN, 인공지능망)

최적화의 많은 알고리즘은 자연현상의 관찰을 토대로 개발됩니다.



Artificial Neural Network(ANN, 인공신경망)

Neural Network(인공신경망) 역시 인간의 뇌가 정보를 처리하는 방식을 이용하여 개발된 알고리즘입니다.



Neuron은 계속해서 시그널을 받아
그것을 조합(**sum**) 하고
특정 threshold가 넘어서면 **fire** 한다

Artificial Neural Network(ANN, 인공지능망)


인공신경망 알고리즘은 Input과 Output 변수 사이에 복수개의 Hidden Layer를 구성하여 노드들 간의 연결 가중치를 반복 학습하는 모델링 방법입니다.

[Neural Network]

NN은 생물학의 신경망에서 영감을 얻은 통계학적 학습 알고리즘으로,
시냅스의 결합으로 네트워크를 형성한 인공 뉴런이 학습을 통해 시냅스의 결합 세기를 변화시켜 문제 해결 능력을 가지는 모델

단층신경망(SLP)는 입력층과 출력층과 한 개의 은닉층으로 구성
입력층은 각 입력변수에 대응되는 노드로 구성되며, 노드의 수는 입력 변수의 개수와 같음
출력층은 출력변수에 대응되는 노드로서 분류 모형에서는 클래스의 수 만큼 출력노드가 생성

다층신경망(MLP)는 입력층과 출력층, 여러 개의 은닉층으로 구성
입력층의 입력에 따라 은닉층의 출력이 나오며, 은닉층의 출력은 다시 출력층에 입력되어 최종 출력이 나옴




Artificial Neural Network(ANN, 인공지능망)

인공신경망 알고리즘을 통하여 데이터와 데이터와의 관계를 해당분야의 전문가가 찾아내는 것이 아니라, 기계가 학습할 수 있습니다.


1

기존모델




2

인공신경망




ANN: 산출 과정

퍼셉트론(Perceptron)을 통하여, (1) 가중치를 합치고, (2) 활성화함수를 통하여 비선형화 하는 과정을 수행합니다.



ANN: 오류역전파


오류역전파(Error Back-Propagation) 알고리즘을 통하여 ANN은 알고리즘의 가중치를 미세조정(Fine-Tuning)합니다.



ANN: Gradient Descending Algorithm


오류역전파(Error Back-Propagation) 알고리즘을 통하여 ANN은 알고리즘의 가중치를 미세조정(Fine-Tuning)합니다.

- 파란색 선: 가중치 w 의 변화에 따른 목적함수 값의 변화
- 검은색 점: 현재 해의 위치
- 화살표: 목적함수를 최적화하기 위해 가중치 w 가 이동해야 하는 방향



Deep Learning

딥러닝(Deep Learning)은 여러 층으로 되어있는 복잡한 구조의 인공신경망 Deep Neural Network(DNN)을 의미합니다.




[Deep Neural Network]

2006년 제프리 힌튼이 비지도 학습을 이용한 전처리 과정을 다층 신경망에 추가하는 방법을 통해 기존 Neural Network의 단점을 보완

2012년 개선된 기법을 객체 인식에 적용하여 오류율을 기존 방식대비 10%가량 떨어뜨리면서 딥러닝이 주목을 받기 시작함


Deep Learning

딥러닝은 고차원의 데이터(이미지, 음성, 텍스트 등)에 대해 속성을 정의하지 않고 원 데이터(Raw Data)를 그대로 사용해도 알아서 속성을 판별할 수 있습니다.



Deep Learning

딥러닝은 기존의 기계학습 방법론에 비해 우수한 예측 정확도를 가집니다. 특정 분야(음성, 이미지 인식 등)에서는 (인간의 능력과 유사할 정도로) 월등히 우수한 성능을 나타내기도 합니다.




Recognition Accuracy for Labeled Faces in the Wild (LFW) dataset (13,233 images, 5,749 people)

- Human: 95% vs. DeepFace in Facebook: 97.35%




Deep Learning: Pre-trained Model

딥러닝은 특정 도메인에서 학습된 구조를 다른 데이터에서 활용할 수 있습니다.



Bilingual Word Embeddings for Phrase-Based Machine Translation,
Will Y. Zou, Richard Socher, Daniel Cer, Christopher D. Manning

“이중 언어 단어 임베딩을 적용하여
중국어-영어 기계 번역 결과를 개선 ”




Zero-Shot Learning Through Cross-Modal Transfer,
Richard Socher, Milind Ganjoo, Hamsa Sridhar, Osbert Bastani,
Christopher D. Manning, Andrew Y. Ng

“트럭, 고양이가 없는 데이터로 학습된 모델을 이용하여
고양이를 인식 ”

Deep Learning: 데이터의 양과 모형의 성능


딥러닝은 기존의 방법론 대비하여 데이터가 늘어남에 따라 지속적으로 모형의 변별력이 높아지는 장점을 가지고 있어서, 빅데이터 시대에 가장 적합한 알고리즘입니다.



From: [Andrew Ng](#)


Deep Learning: 주요 개념 - Activation Function

ReLU를 활용하면서 기존의 Sigmoid 함수 류의 Activation Function가 가지는 Gradient Vanishing Problem 등을 해결하게 되었습니다.



$$step(x) = \begin{cases} 0 & \text{if } x < 0 \\ 1 & \text{if } x \geq 0 \end{cases}$$

$$ReLU(x) = \max(x, 0)$$




$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

$$Maxout(x) = \max(b_1 + w_1x, b_2 + w_2x, \dots)$$

Deep Learning: 주요 개념 - Dropout


ReLU를 활용하면서 기존의 Sigmoid 함수 류의 Activation Function가 가지는 Gradient Vanishing Problem 등을 해결하게 되었습니다.




랜덤한 확률로 Node를 제거하는 방식으로 학습을 시키고,
실제 탑재시에는 Node에 결합된 Weight에 대하여 Drop Out 가중치를 부여함

Deep Learning: 주요 개념 - Regularization

Regularization을 활용하여 과적합을 방지할 수 있습니다. L1(Lasso), L2(Ridge)의 두 가지 종류의 제약조건이 포함될 수 있습니다.



Rectifier, hidden=[50,50]



**RectifierWithDropout, hidden=[50,50],
l1=1e-4, l2=1e-4, hidden_dropout_ratio=[0.2,0.3]**


<http://www.slideshare.net/0xdata/h2o-world-top-10-deep-learning-tips-tricks-arno-candel>

Deep Learning: 주요 학습 기법

딥러닝은 복잡한 Neural Network를 학습시키기 위하여 비지도 학습을 이용한 전처리 과정을 통하여 그 성능을 크게 향상시킵니다.


Topics: unsupervised pre-training

- We will use a greedy, layer-wise procedure
 - ▶ train one layer at a time, from first to last, with unsupervised criterion
 - ▶ fix the parameters of previous hidden layers
 - ▶ previous layers viewed as feature extraction



Deep Learning: 주요 학습 기법

딥러닝은 Stacked Auto Encoder와 같은 비지도 학습을 이용한 전처리 과정을 통하여 차원을 축소하고, 노이즈를 감소시켜 이후 단 지도학습 모형의 복잡도를 감소합니다.



<http://www.slideshare.net/anastasiakornilova/neural-networks-and-deep-learn>

INDEX

Knowledge, Information, Solution

03 AI 알고리즘


(1) 회귀분석

(2) Deep Learning

(3) Decision Tree

Decision Tree

Decision Tree는 사람이 이해할 수 있는 규칙 형태로 결과가 나오고, 데이터의 사전적인 처리를 할 필요가 없다는 점, 수치/범주형 변수를 모두 다룰 수 있다는 점에 장점이 있습니다.



- 한번에 하나의 변수를 활용하여 예측을 하기 위한 규칙을 생성함
- 최종 결과물은 나무를 뒤집어 놓은 형태의 규칙의 집합
- Decision Tree의 경우 이해하기 편하면서도 매우 강력하나 과적합이 잘 될 수 있으므로, Pre-Pruning(Early Stopping) 혹은 Post-Pruning을 통하여 제어함

Tree | 나무를 뒤집어 놓은 형태의 규칙 집합

Node | 특정 기준에 따라 분할된 지점. Root Node에서 시작

Level | 트리 깊이에 대한 시퀀스. Root는 0-Level

Leaf | 분할이 없는 마지막 노드

Tree Split Algorithm

Decision Tree는 데이터마이닝 기반(엔트로피, Information Gain)의 ID3, c4.5, C5.0 등과, 통계적 기반(Gini Index)의 CHAID, CART등의 알고리즘에 따라 구분됩니다.

[Decision Tree(C5.0)]

호주의 연구원 Quinlan 에 의하여 1993년에 개발
C4.5 분류 알고리즘의 확장 버전인 C5.0 알고리즘을 사용
C&RT와는 다르게 각 마디에서 multi split이 가능하며,
범주형 입력변수에 대해서는 범주의 수만큼 분리 일어남
불순도의 측도로는 엔트로피지수를 사용

❖ m개의 레코드가 속하는 A 영역에 대한 엔트로피

$$Entropy(A) = -\sum_{k=1}^m p_k \log_2(p_k)$$

- p_k = A영역에 속한 레코드 중 k 범주에 속하는 레코드의 수



$$\begin{aligned} E(A) &= -\sum_{k=1}^m p_k \log_2(p_k) \\ &= -\frac{6}{16} \log_2\left(\frac{6}{16}\right) - \frac{10}{16} \log_2\left(\frac{10}{16}\right) \\ &\approx 0.95 \end{aligned}$$

- 엔트로피는 0 (모든 레코드가 한 범주에 속함) 부터 $\log_2(m)$ (모든 범주에 속하는 개체의 비율이 동일)


[Decision Tree(C&RT)]

1984년에 Breiman 등이 개발하였고, 가장 널리 사용되는
의사결정나무 알고리즘
범주형과 연속형 타겟을 모두 분류할 수 있으며, 불순도의
측도로써 출력변수가 범주형인 경우 지니 지수를 이용하고,
출력변수가 연속형인 경우에는 분산을 이용하여 이진
분리(Binary split)

❖ m개의 레코드가 속하는 A 영역에 대한 지니 계수

$$I(A) = 1 - \sum_{k=1}^m p_k^2$$

- p_k = A영역에 속한 레코드 중 k 범주에 속하는 레코드의 수




$$\begin{aligned} I(A) &= 1 - \sum_{k=1}^m p_k^2 \\ &= 1 - \left(\frac{6}{16}\right)^2 - \left(\frac{10}{16}\right)^2 \\ &\approx 0.47 \end{aligned}$$

- 모든 레코드가 동일한 범주에 속할 경우 $I(A) = 0$
- 두 개의 범주에 속하는 개체의 수가 동일할 경우 $I(A)=0.5$


Tree Split Algorithm

재귀적 분기 과정을 통하여 순도가 100%가 되도록 트리를 가르고, 과적합을 방지하기 위하여 적절히 가지치기 하는 과정을 거치게 됩니다.

재귀적 분기




가지치기



Tree Split Algorithm: 가지치기

의사결정나무는 Full Tree를 생성한 뒤 적절한 수준에서 말단 노드를 결합하는 가지치기 수행합니다. 이때 비용 복잡도(cost complexity) 를 사용하여 최적의 의사결정나무 구조 선택합니다.




$$CC(T) = Err(T) + \alpha \times L(T)$$

- $CC(T)$ = 의사결정나무의 비용 복잡도 (낮을수록 우수한 의사결정나무)
- $Err(T)$ = 검증데이터에 대한 오분류율
- $L(T)$ = 말단 노드의 수 (구조의 복잡도)
- α = $Err(T)$ 와 $L(T)$ 를 결합하는 가중치 (사용자에 의해 부여됨)

Ensemble Tree: Bagging


과적합 가능성이 높은 Single Tree를 앙상블 기법을 통하여 개선할 수 있습니다.

Bagging은 Bootstrap*으로 생성된 샘플을 학습하고, 이를 결합하여 강력한 모델을 생성합니다.



Random Forest

Random Forest는 앙상블 학습 방법의 일종으로, 다수의 Decision Tree로부터 평균 예측치를 구하여 모형적합을 수행합니다.



[Random Forest]

랜덤 포레스트는 의사결정 나무의 확장 개념


의사 결정 나무는 하나의 데이터 집합에서 한번의 훈련용 데이터를 생성하고 학습하여 하나의 트리를 생성하지만,

랜덤 포레스트는 동일한 하나의 데이터 집합에서 임의의 복원 샘플링을 통해 여러 개의 훈련용 데이터를 만들어 여러 번의 학습을 통해 여러 개의 트리를 생성하고, 이들을 결합해 최종적으로 목표 변수를 예측

랜덤 포레스트는 앙상블 기법인 배깅(Bagging)을 사용한 임의의 노드 최적화라고 할 수 있음


Ensemble Tree: Boosting

Boosting은 순차적으로 학습과 예측을 하면서 이전 학습된 모형의 예측이 틀린 데이터에 가중치를 더 많이 부여하여 추가 학습을 진행하는 방식입니다.



Gradient Boosting Machine

Gradient Boosting Machine(GBM)은 Decision Tree의 시퀀스 학습을 통해 예측 모델을 생성하며, 이전 Tree의 예측 오류를 수정해 나가며 모형적합을 수행합니다.



<http://statweb.stanford.edu/~jhf/ftp/trebst.pdf>

[Gradient Boosting Machine]

GBM은 회귀분석과 분류에 대한, 예측력이 약한 모델들을 결합하여 강한 예측 모델을 만드는 알고리즘

Freidman은 부스팅 알고리즘을 최적화 알고리즘의 하나인 기울기 강하(Gradient Descent) 알고리즘으로 해석하였으며, 이를 통하여 지수 손실 함수 이외의 다양한 손실함수에서 부스팅 알고리즘을 개발


GBM은 시퀀스 학습을 통해 예측 모델을 생성하며, 이전 Tree의 예측 오류를 수정해 나가며 모형적합을 수행

XGBoost / LightGBM

XGBoost와 LightGBM 은 Gradient Boosting Machine에서 발전된 형태의 Boosting Tree입니다. 과적합을 제어하면서도 더 높은 성능을 보이는 알고리즘입니다.


XGBoost eXtreme Gradient Boosting, 2014

- Gradient Boosting Machine의 변종
- 정규화(L1, L2)된 Gradient Boosting 기법 적용
- 다중 스레드 처리를 지원하여 빠른 학습 속도
- 많은 메모리 사용(시스템 리소스 필요)
- 깊이를 줄이고 너비를 확장하는 방식



LightGBM, 2017

- Gradient Boosting Machine의 변종
- 히스토그램 기반의 Gradient Boosting 기법을 사용하여 빠른 학습 속도
- 리프 중심 트리 분할 방법을 사용하여 낮은 메모리 사용
- 깊이를 늘리고 트리를 깊게 확장하는 방식



INDEX

Knowledge, Information, Solution

04 설명가능한 인공지능

(1) XAI 정의


(2) LIME

(3) SHAP

(4) 사유코드

(5) 분석 사례

설명가능한 인공지능(XAI: eXplainable AI) 는 AI 모델의 복잡한 과정을 통하여 도출한 결과값의 원인과 작동원리를 사람들이 이해할 수 있도록 표현하는 기술 또는 방법론을 의미합니다.



* 출처: DARPA(Defense Advanced Research Projects Agency)


인공지능의 성능 향상을 위해서 시작된 XAI는 인간의 권익 보호라는 관점으로 패러다임이 변화하고 있습니다. 해석가능성이라는 키워드에서 투명성, 공정성, 책임이 더 중요한 요소로 자리잡고 있습니다.



- ✓ AI의 결정이나 예측을 동작을 사람이 **해석**할 수 있는 형태로 변환하기 위한 기술과 방법론
- ✓ 블랙박스 구조에서 생성된 결정을 인간에게 이해시킴으로써 **신뢰성**과 **정당성**을 제공하는 것
- ✓ 개별적인 결정의 인과관계를 투명하고 신뢰할 수 있도록 하는 활동이나 노력

XAI : AI신용평가와 XAI

머신러닝을 이용한 예측 모델은 속도, 재현성, 확장성 측면에서 큰 장점이 있는 반면, 예측의 정확도에 집중할수록 모형의 내부 매커니즘이 복잡해지고 이를 직접적으로 해석하는 것은 불가능에 가깝습니다.



White-Box(Interpretable)

- Regression
- Decision Tree
- Decision Rule
- RuleFit
- ...

Black-Box

- Deep Learning
- GBM
- XGBoost
- Random Forest
- ...

Explain Method

※ 복잡도: 모형 산출을 위한 Rule의 개수

※ KS: Kolmogorov-Smirnov 통계량.

Binary Classification 문제에서 2개 Class 간의 분포의 차이를 나타내며, 값이 클수록 모형의 성능이 높음을 의미함.

XAI : AI신용평가에서 설명의 목적

고객에게 심사 결과를 이해시키기 위해서는 좋은 설명이 필요합니다. 좋은 설명은 명확하고 간결하며 이해하기 쉬운 방식으로 정보나 개념을 효과적으로 전달하는 것입니다. 청자의 지식 수준을 고려해야 하며, 공감할 수 있는 언어와 예시가 필요합니다.



평점이 왜 700점 인가요?



결과를 정확하게 설명

설명에 AI시스템의 내부 동작원리를 충실하게 반영해야 하며 실제 결과값을 정확하게 대표해야 함



반대 사실의 설명

관심 대상과 참고 대상의 가장 큰 차이를 부각시키는 것이 사람의 인지 패턴과 유사하며 이해하기가 쉬움



어떻게 하면 점수를 올릴 수 있나요?



비슷한 입력값에 대한 설명

동일한 입력값에 대해서 동일한 설명을 산출해야 하며 비슷한 입력값에 대해서는 비슷한 설명을 할 수 있어야 설명을 신뢰할 수 있음



현재 시스템내에서 설명

기존의 금융 시스템 하에서 AI모형을 충분히 설명할 수 있어야 고객과 원활한 소통이 가능함

AI는 Deep Learning을 중심으로 높은 성능을 보이며 발전하고 있습니다. XAI 측면에서 모형의 학습 단계에서부터 해석가능한 방법론에 대한 연구도 진행되고 있지만 블랙박스 모형을 설명해내고자 하는 방향으로 진행되고 있습니다.


해석가능한 알고리즘

알고리즘 자체로 해석 가능한 모형 또는 방법론
회귀분석과 같은 통계적 방법론에 기반한 머신러닝 모형

1. **Logistic Regression** 분류 문제를 위한 대표적인 회귀모형

$$\ln\left(\frac{P(Y = 1|X)}{1 - P(Y = 1|X)}\right) = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$$

2. **Decision Rule** IF-THEN 구조의 Rule




알고리즘	선형성	상호작용
Regression	O	X
Rule	X	O
RuleFit	O	O

3. **Scorecard** AI알고리즘의 결과를 표 형태로 변환하여 출력값을 설명

- ① Logit Scorecard: 개별 항목의 Encoding을 통한 전통적인 평점표
- ② Boosting Scorecard: Boosting계열(XGBoost, LightGBM)의 결과를 분해하여 평점표 형태로 표현한 방법론

사후 설명 방법론

Black-box Model을 설명하기 위한 방법으로
모형의 결과를 간접적으로 해석하고 설명




1. **Global Model-Agnostic Methods**

머신러닝 모델의 평균적인 결과를 설명하는 방법
모델 자체의 특성을 이해하기 위해서 사용
ex) Surrogate Model, Partial Dependence Plot, ...

2. **Local Model-Agnostic Methods**

개별 데이터에 대한 설명을 위한 방법
개별 데이터의 산출 원인을 구체적으로 확인하기 위해 사용
ex) LIME(Local Surrogate), SHAP, ...

XAI: 계층도



Ante-Hoc / Intrinsic / Interpretable Models

방법론(알고리즘)이 본질적으로 해석 가능한 방법론
XAI를 위한 추가적인 방법이 필요하지 않으며 모형의 결과를 바탕으로 표현(시각화 등)함으로써 설명을 제공
사후설명을 위한 방법론으로 활용 가능

Post-Hoc

사후 설명 방법론
Deep Learning으로 대표되는 Machine Learning의 많은 알고리즘이 모형의 내부 구조를 직접 해석하기 어렵게 구성되어 있으며, 복잡한 모형을 설명하기 위해서 별도의 방법론을 적용


Model-Specific

원 모형의 알고리즘 종류에 제한적으로 적용할 수 있는 XAI 방법론
Interpretable Models은 모형 특화 성격을 가지고 있음

Model-Agnostic

모형의 종류에 상관없이 적용 가능한 XAI 방법론
Deep Learning을 포함하여 여러가지 알고리즘이 결합된 앙상블 형태의 모형에도 적용가능한 방법론

XAI: 계층도



XAI : 연구사례

AI시스템을 설명하기 위해서 학술적으로 다양한 연구가 존재합니다.

이러한 다양한 기법을 활용하여 AI시스템의 설명력을 확보하고 적용 범위를 확대할 수 있습니다.


Model agnostic	LIME	Approximate the complex model near a given prediction. - Ribeiro et al. 2016
	Shapley value sampling / Quantitative Input Influence	Feature importance for a given prediction using game theory. - Štrumbelj et al 2014, Datta et al. 2016
Neural networks	Layer-wise relevance prop	Back propagates neural network explanations. - Bach et al. 2015
	DeepLIFT	Difference from a reference explanations of neural networks. - Shrikumar et al. 2016
Linear	Shapley regression values	Explain linear models in the presence of collinearity. - Gromping et al. 2012
Trees	TreeSHAP	Consistent individualized feature attribution for tree ensembles.- Lundberg 2018

XAI : Global Surrogate Model


Global Surrogate Model은 Black-Box 모형의 결과를 해석 가능한 알고리즘을 활용하여 새로운 모형을 생성하는 방법론입니다. Black-Box 모형의 많은 부분을 해석하고 설명할 수 있습니다.




- 모형의 반응변수(Target)
- 모형의 Input을 공통으로 사용



- Black Box 모형 생성
- Performance 위주의 모형 선택




- 예측치 산출: 확률→평점(정수)
- White-Box Model의 반응변수
- Train Set의 전체 또는 일부 사용



- White-Box Model 생성
- 해석 가능한 모든 알고리즘 가능
- Linear Regression을 기반으로 한 평점표 방법론 활용



- 모형의 일반적인 특성을 효율적으로 설명
- 특정 데이터(row)에는 적용되지 않을 수 있음



XAI: PDP(Partial Dependence Plot)

Partial Dependence Plot 은 특정 변수의 입력값 변화에 따른 모델의 결과값 변화를 시각적으로 표현합니다.
특정 변수의 값에 따른 결과값의 평균적인 수준을 근거로 모형을 설명합니다.



- 개별 변수가 결과값에 미치는 한계 효과를 시각화
- 선형 회귀모형에서는 항상 직선
- 개별 항목을 독립이라고 가정

f(x)

- 특정 변수의 모든 값에 대한 모델의 결과값을 평균
- $\hat{f}_S(x_S) = \int \hat{f}_S(x_S, X_C) dP(X_C) = \frac{1}{n} \sum_{i=1}^n \hat{f}_S(x_S, x_C^i)$

X1	X2	X3
1	0.32	18
2	0.31	-24
2	3.7	-220
1	0.48	-74
3	-0.61	219

X1	X2	X3	Output
1	0.32	18	50
1	0.31	-24	60
1	3.7	-220	70
1	0.48	-74	80
1	-0.61	219	90

70

⋮



- Step1. 학습 데이터에서 특정 변수의 모든 유일값 확인
- Step2. 유일값에 대해서 반복 수행
- Step2-1. 특정 변수의 값을 정해진 하나의 값으로 수정
- Step2-2. 블랙박스 모형의 결과값 산출
- Step3. 모든 유일값에 대한 모형의 결과값을 평균



- ALE(Accumulated Local Effect)
2개 변수에 대한 영향도 확인
- ICE(Individual Conditional Expectation)
PDP와 유사하나 산출된 모든 값에 평균을 적용하지 않고
모든 행을 시각화




X1	X2	X3	Output
3	0.32	18	30
3	0.31	-24	40
3	3.7	-220	50
3	0.48	-74	60
3	-0.61	219	70

50

XAI : Local Surrogate Model

Local Surrogate Model은 특정 Point(Data Row)에 대하여 해석하기 위한 방법론입니다.
특정 영역에서의 설명력이 높으면서도 복잡도가 낮은 모형을 활용하여 예측값을 설명합니다.



XAI : LIME

LIME은 블랙박스 모델의 예측을 지역적으로 근사함으로써 모형의 결과를 설명합니다.

블랙박스 모델이 분류 모델의 퍼포먼스에 집중했다면 LIME은 해당 모델이 왜 특정값을 산출했는지에 집중합니다.




- Local Interpretable Model-agnostic Explanation
- 특정 예측값 근처에서 지역적으로 해석하기 위한 방법론



- Random Points를 생성(샘플링)하고 Black Box 모형의 예측값 산출
- 관심 Data Point는 고려하지 않음




- 관심 Data Point와의 근접도 산출
- 가까울수록 높은 가중치 부여



- Sample Data를 활용하여 학습
- White-Box Model 생성
- 해석 가능한 모든 알고리즘 가능



- Model-Agnostic(모든 알고리즘에 적용 가능)
- 특정 Point에 대한 간단하면서도 직관적인 설명
- 결과의 일관성이 없고 **많은 시간이 소요됨**




* 출처: Interpretable Machine Learning, Christoph Molnar

XAI : LIME

LIME은 선택된 특정 Row가 산출된 주요 요소를 시각화와 함께 범주화된 형태로 표현하여 Black-Box 모형의 결과값 산출 이유를 설명합니다. 단, 개별 요인과 결과값의 증감에 대한 부분은 설명하지 않습니다.


Case 1

Prediction probabilities



Good

Bad



ExternalRiskEstimate ≤ 63


-7 < MSinceMostRecentInqexcl7days ≤ 0

Feature Value

ExternalRiskEstimate	60.00
MSinceMostRecentInqexcl7days	0.00


Case 2

Prediction probabilities



Good

Bad



ExternalRiskEstimate > 79

-7 < MSinceMostRecentInqexcl7days ≤ 0

Feature Value


ExternalRiskEstimate	81.00
MSinceMostRecentInqexcl7days	0.00

XAI : SHAP


SHAP(SHapley Additive exPlanations)은 게임이론에 근거한 기여도를 산출하여 모형의 예측값을 설명합니다. 모든 항목의 조합에 대하여 기여도를 비교하며, 연산 속도 개선을 위한 연구가 계속되고 있습니다.



- 게임이론에 기반한 Shapley value를 활용한 XAI
- 조건부 기댓값을 활용해서 기여도를 계산하고 기댓값의 변화량으로 데이터 설명



- 항목의 모든 조합에 대하여 기여도 계산
- k개 항목 $\rightarrow 2^k$ 개의 조합
- Approximate 를 위한 연구 진행



- Kernel SHAP: Model-Agnostic
- LIME과 Shapley Values의 결합
- 느린 연산 속도



- TreeSHAP Model-Specific
- 트리 기반의 알고리즘에만 적용 가능
- 빠른 연산 속도




- 특정 Data에 대한 항목별 기여도를 직관적으로 설명
- Local Explain을 통한 Global Explain 가능


Image

Coalitions of superpixels $\xrightarrow{h_x(z')}$ Image

Instance x



Instance x with absent features



Tabular

Coalitions $\xrightarrow{h_x(z')}$ Feature values

Instance x

$$x' = \begin{array}{c|c|c} \text{Age} & \text{Weight} & \text{Color} \\ \hline 1 & 1 & 1 \end{array}$$

$$x = \begin{array}{c|c|c} \text{Age} & \text{Weight} & \text{Color} \\ \hline 0.5 & 20 & \text{Blue} \end{array}$$

Instance with "absent" features

$$z' = \begin{array}{c|c|c} \text{Age} & \text{Weight} & \text{Color} \\ \hline 1 & 0 & 0 \end{array}$$


$$z = \begin{array}{c|c|c} \text{Age} & \text{Weight} & \text{Color} \\ \hline 0.5 & \cancel{20} & \cancel{\text{Blue}} \\ & \downarrow & \downarrow \\ & 17 & \text{Pink} \end{array}$$

* 출처: Interpretable Machine Learning, Christoph Molnar

XAI : SHAP

2018년에 제안된 Tree SHAP은 빠르게 AI모형을 설명하면서 크게 각광받았습니다.


Tree의 경로에 따라 기여도(Shapley value)를 산출하고 이를 이용하여 개별 항목값과 AI모형 출력값 사이를 설명합니다.




XAI : SHAP

SHAP을 이용하면 개별 변수가 Black-Box 모형의 출력값에 미치는 영향을 쉽게 확인할 수 있습니다.
개별 변수의 값을 색깔의 변화로 표현하고 결과값에 미치는 정도를 시각화합니다.

Dot Plot(Beeswarm Plot)



Waterfall Plot




* 결과값이 작아질수록(우량 경향) External Risk Estimate가 큰 값(붉은색)으로 표시

XAI: 사유코드

사유코드는 전통적인 신용평가모형 개발 방법론을 AI신용평가모형의 설명을 위하여 적용한 방법론입니다. AI모형의 산출 결과를 Target으로 Global Surrogate Model을 생성하고 평점표 형태로 표현합니다.


- 1 개별 항목 범주화**
각각의 항목을 AI모형의 출력값에 유의미한 차이가 나도록 범주화
- 2 개별 항목 Recode**
범주화된 항목을 AI출력값의 크기 (방향)에 맞게 Encoding
- 3 Regression**
범주화된 항목을 기준으로 회귀분석 수행
- 4 평점표 형태 구성**
회귀분석의 결과를 평점표 형태로 구성하여 설명력 확보



no	name	recode	coef	diff	sign	prior	min	max	count	score
0	Intercept	0	342.969815	0.000000	pos	17	NaN	NaN	8367.0	492.618979
1	cc_AverageMInFile	0	0.000000	-9.187520	neg	5	-9.0	52.0	2095.0	448.706444
1	cc_AverageMInFile	1	5.584086	-3.603433	neg	14	53.0	70.0	1757.0	478.911212
1	cc_AverageMInFile	2	21.978472	12.790953	pos	3	71.0	383.0	4515.0	518.329125
2	cc_ExternalRiskEstimate	0	0.000000	-36.713909	neg	1	-9.0	67.0	3328.0	432.571514
2	cc_ExternalRiskEstimate	1	32.579909	-4.134000	neg	11	68.0	74.0	1847.0	483.130482
2	cc_ExternalRiskEstimate	2	77.561818	40.847909	pos	1	75.0	93.0	3192.0	560.715226

XAI: 분석사례

개발 단계에서 AI신용평가모형을 설명하기 위한 분석 사례 입니다.
General AI 방법론에 대하여 설명가능한 인공지능 방법론을 적용하였습니다.



대상자 BS 고객군 중 연체 경험 Setment

Target 6개월 채무불이행 경험 또는 연체 30일 이상

개발시점 2022.07~2022.12


특징

- ① General AI 모형(LightGBM)의 변별력이 가장 우수
- ② 모든 방법론에서 시계열 패턴이 보이며,
- ③ 테스트 시점에 대한 성능의 안정성 또한 General AI 모형이 가장 우수함

XAI: 분석사례

AI신용평가모형 개발 결과입니다.

확률값으로 산출된 SI알고리즘의 결과를 신용평가 실무에 적합한 평점 형태(0~1000)로 변환하였습니다.




$$Score = 500 + 40 \times \log \left(\frac{1 - Prob.of\ bad}{Prob.of\ bad} \right) / \log(2)$$

XAI: SHAP 분석 예시

SHAP을 이용하면 항목이 AI모형의 결과값에 미치는 영향을 개별 항목 수준에서 확인할 수 있습니다.
금융업권에서 보편화된 방법론은 아니며, TreeSHAP을 기반으로 확산되고 있으나 표현 방식의 제한이 있습니다.

Beeswarm


- ✓ 개별 항목의 값이 출력값에 어떤 영향을 미쳤는지 전체적으로 확인
- ✓ 가로축의 값이 클수록 모형 결과에 가점
- ✓ 개별 항목의 값이 클수록 빨간색, 작을수록 파란색에 가깝게 표현



불량(Target=1)에 대한 기여도

Waterfall


- ✓ 개별 데이터(금융 소비자 1명)에 대한 출력값을 항목별로 분해
- ✓ 가점과 감점을 각각 빨간색, 파란색으로 표현하며 높은 정확도
- ✓ 평점 상승을 위한 대안을 찾기 어려움(낮은 대조성)




XAI: SHAP 분석 예시

Force Plot은 AI모형의 각 특성(항목)이 출력값에 영향을 미치는 기여도를 구조적으로 시각화합니다.
전체 데이터에 대한 Force Plot을 이용해서 특성과 특성 간의 관계도 확인할 수 있습니다.

Instance Force Plot






Overall Force Plot






XAI: PDP 분석 예시

Partial Dependence Plot 은 특정 변수의 입력값 변화에 따른 모델의 결과값 변화를 시각적으로 표현합니다. 특정 변수의 값에 따른 결과값의 평균적인 수준을 근거로 모형을 설명합니다.

최초신용카드발급기간






대출총건수






XAI: PDP 분석 예시

Partial Dependence Plot 은 특정 변수의 입력값 변화에 따른 모델의 결과값 변화를 시각적으로 표현합니다. 특정 변수의 값에 따른 결과값의 평균적인 수준을 근거로 모형을 설명합니다.

결제금예비용



최고할도소진율




XAI: PDP 분석 예시


Partial Dependence Plot 은 특정 변수의 입력값 변화에 따른 모델의 결과값 변화를 시각적으로 표현합니다.
특정 변수의 값에 따른 결과값의 평균적인 수준을 근거로 모형을 설명합니다.

CL,CA,RV 사용기관수


불량률






기여도



평균 평점



CA이용잔액



XAI : 사유코드 분석 예시

사유코드는 모형 구성단계에서 사회적 의미와 설명을 고려하기 때문에 직관적으로 좋은 설명을 제공할 수 있습니다. 항목별 사유코드를 정의하고 그에 대한 설명을 미리 만들어 놓기 때문에 숙련도에 따른 어려움이 없습니다.

항목명	Class	범위	사유코드	사유코드 설명
최초신용카드발급	0	1년 미만	N002	신용활동 기간 부족
	1	1년~5년	N006	신용활동 기간 짧음
	2	5년~10년	P009	신용활동 기간 양호
	3	10년 이상	P001	신용활동 기간 우량
CA이용잔액	0	100만원이상	N009	CA이용 잔액 과다
	1	10만원 이상	N015	CA이용 잔액 보유
	2	10만원 미만	P002	CA이용 잔액 없음
카드론,CA,리볼빙이용기관수	0	3개 이상	N003	금융 상품 이용 기관수 과다
	1	1개~2개	N012	금융 상품 이용중
	2	0개	P004	금융 상품 이용 없음
SP대출건수	0	2건 이상	N011	Sub Prime 업권 대출 과다
	1	1건 이상	N027	Sub Prime 업권 대출 보유
...				

XAI : 사유코드 분석 예시

설명이 필요한 주요 고객층(평점이 낮은 고객군)의 감점 사유를 효율적으로 설명할 수 있습니다.
금융업권에서 가장 많이 사용하고 있는 AI신용평가모형 설명 방법론입니다.

고객번호

P123456

고객이름

홍길동

평점결과

652

평가일시

2022-10-27

긍정사유1

P002

6개월 내 신규 대출 없음

상세

긍정사유2

P005

신용대출 없음

상세

긍정사유3

P010

미해제 채무불이행 없음

상세

부정사유1

N002

최근1년 내 채무불이행 경험

상세

부정사유2

N005

미해제 연체 보유

상세

부정사유3


N007

최근1년 내 대출기관 과다(3건 이상)

상세

No	범위	스코어	사유코드	사유코드 설명
0		0.00		
1	null,1<=[B32000200]	0.00	N001	미해제 채무불이행 보유
2	[B32000200]<1	128.59	P010	미해제 채무불이행 미보유
3	null,1<=[BS0000664]<1095	0.00	N002	최근3년내 채무불이행 경험
4	1095<=[BS0000664]	29.38	N004	최근5년내 채무불이행 경험
5	[BS0000664]<1	122.12	P009	최근5년내 채무불이행 미경험
6	null,[C00000090]<365	0.00	N014	신용카드 실적 미비(최초 카드 발급 1년 이내)
7	365<=[C00000090]	58.62	P008	신용카드 실적 보유

WHY? 감점사유 산출 비율



- 감점 사유가 산출되지 않은 대상
- 감점 사유가 1개 이상 산출된 대상

Discover More
Information



Create Further
Knowledge



Deliver Better
Solutions



감사합니다.